

Aula 01

Introdução ao Processamento de Linguagem Natural (**PNL**)

PROCESSAMENTO DE LINGUAGEM NATURAL - IBM3130

Prof. Anderson Vanin

1. Introdução

Antes de falar em computadores, algoritmos ou modelos de inteligência artificial, é preciso começar pelo começo: **o que é linguagem, linguagem natural e processamento de linguagem natural ?**

1.1. Linguagem

Linguagem é o **sistema simbólico** que os seres humanos desenvolveram para **representar o mundo, organizar o pensamento e compartilhar experiências com outros.**

1.1. Linguagem

Algo fundamental: linguagem não é só o que se diz — é o que se quer dizer, o **contexto** em que se diz, e o que o outro **entende** a partir disso.

Essa tríade — **intenção, contexto e interpretação** — é o que torna a linguagem simultaneamente o meio de comunicação mais poderoso e o mais difícil de formalizar.

1.2. Linguagem Natural

Linguagem natural é aquela que surge espontaneamente nas comunidades humanas, sem projeto deliberado.

1.2. Linguagem Natural

Ela **evolui** com o tempo, **varia** entre regiões e gerações, admite **ambiguidade**, **erro**, **ironia**, **gíria**, **metáfora** e **silêncio**.

1.2. Linguagem Natural

É resiliente: mesmo com palavras faltando, pronúncia errada ou frase incompleta, os falantes se entendem porque complementam o que ouvem com **conhecimento de mundo, experiência social e intuição contextual.**

1.3. Linguagem Formal

Linguagem formal, por outro lado, é projetada com **regras rígidas** e sem espaço para ambiguidade — é o caso das **linguagens de programação**, da **notação matemática**, do **SQL**.

Cada símbolo tem exatamente um significado; qualquer desvio da sintaxe resulta em erro. **Não há subentendidos**, **não há ironia**, **não há "mais ou menos"**.

1.4. Processamento de Linguagem Natural

Processar linguagem, portanto, não é apenas ler caracteres. É **extrair significado** de algo que foi construído por e para seres humanos, com **todas as suas complexidades, contradições e riquezas.**

A Ilusão da Magia Cotidiana

A linguagem natural já guia nossa rotina digital. O que parece inteligência intuitiva é, na verdade, cálculo de alta precisão.



Assistentes Virtuais

Alexa, toca música... (Speech-to-Text & Compreensão).



Tradução em Tempo Real

Google Translate processando 100 bilhões de palavras por dia.



Busca Semântica

O Google entendendo a intenção da sua pergunta médica, não apenas as palavras-chave.



Geração de Conteúdo

ChatGPT e Claude redigindo e-mails, códigos e resumos instantaneamente.

2. O Problema dos 80%

Estima-se que entre **80% e 90%** de todos os dados produzidos no mundo são não estruturados — e a maior parte deles está em forma de texto, linguagem humana (CASELI; NUNES, 2023; SUMATHI; JANANI, 2020).

O Maior Repositório de Informação do Mundo



80%



Estima-se que mais de 80% de toda a informação corporativa global esteja em **formato textual não estruturado** (Caseli; Nunes, 2023).

Sem PLN, esse volume colossal de dados é **computacionalmente invisível** e **humanamente impossível** de analisar.

2.1. Dados estruturados e não estruturados

Dado estruturado: formato predefinido, organizado em campos com tipos e relações conhecidas antecipadamente.

Dado não estruturado: não segue um esquema predefinido, significado não pode ser extraído diretamente por regras formais.

2.2. O abismo entre dado e informação


Ter o dado não significa ter a informação.

2.2. O abismo entre dado e informação

Exemplo: Um hospital pode armazenar digitalmente 2 milhões de prontuários médicos dos últimos 20 anos.

- *Quantos pacientes com mais de 60 anos apresentaram um determinado conjunto de sintomas nos últimos 5 anos?*
- *Quais medicamentos foram prescritos?*
- *Qual foi a taxa de readmissão?*

A intersecção entre o humano e o computável



3. O encontro de dois mundos

PLN é a tentativa de aproximar dois mundos que foram construídos por princípios opostos.

3. O encontro de dois mundos

- **MUNDO HUMANO** — fluido, ambíguo, contextual, emocional, culturalmente situado, construído ao longo de milênios de evolução biológica e social.
- **MUNDO COMPUTÁVEL** — preciso, formal, determinístico, construído sobre lógica binária e operações matemáticas definidas.

3. O encontro de dois mundos

Os três pilares que sustentam o Processamento de Linguagem Natural: a **Linguística**, a **Ciência da Computação** e a **Inteligência Artificial**.

3.1. A Linguística — compreender o que a linguagem é

- **Fonologia e fonética:** estudam os sons da linguagem.
- **Morfologia:** estuda a estrutura interna das palavras.
- **Sintaxe:** estuda como as palavras se combinam para formar frases gramaticalmente corretas.
- **Semântica:** estuda o significado.
- **Pragmática:** estuda como o significado é construído na interação.

3.2. Ciência da Computação — tornar o processamento possível

“Como processamos isso em escala?”

- Algoritmos e estruturas.
- Representação formal de linguagem.
- Teoria da informação forneceu as ferramentas matemáticas para quantificar a informação
- Engenharia de software e infraestrutura

A contribuição central da ciência da computação para o PLN é a capacidade de operacionalizar — de transformar uma teoria sobre linguagem em um sistema que funciona, que escala e que produz resultados mensuráveis em dados reais.

3.3. Inteligência Artificial — aprender a partir dos dados

A grande virada: o **Aprendizado de Máquina**

Em vez de programar as regras, deixe o sistema aprendê-las a partir de exemplos.

- **Aprendizado de máquina supervisionado.**
- **Aprendizado não supervisionado.**
- **Redes neurais profundas: aprender representações hierárquicas da linguagem**
- **Aprendizado por transferência e modelos pré-treinados.**

Máquinas exigem regras. Humanos comunicam-se em exceções.

Linguagem Natural

- **Ambiguidade:** Alta ('banco' pode ser assento, dinheiro ou rio)
- **Contexto:** Imprescindível (depende de conhecimento implícito e de mundo)
- **Evolução:** Fluida (admite gírias, erros e muda com a cultura)

Linguagem Formal / Código

- **Ambiguidade:** Zero (cada símbolo tem um único significado)
- **Contexto:** Explícito (variáveis devem ser declaradas)
- **Evolução:** Estática (muda apenas em novas versões formais)

O desafio fundamental do PLN é forçar a geometria exata do código sobre o caos orgânico da linguagem.

O Abismo entre o Humano e a Máquina

Linguagem Natural



Linguagem Formal



Ambiguidade

Alta (Banco pode ser assento, instituição ou margem).

Zero (Cada símbolo tem um significado único).

Contexto

Imprescindível (Ela foi exigida para saber quem é ela).

Explícito (Variáveis declaradas antes do uso).

Estrutura

Permite erros, gírias e elipses sem perder a comunicação.


Um erro de sintaxe gera falha total de compilação.

Evolução

Orgânica, muda com a cultura e gerações.

Controlada, muda apenas por atualizações de versão.

A Hierarquia da Compreensão



4. A Hierarquia da Compreensão

Quando um ser humano lê a frase "*o médico disse que o paciente não resistiu ao tratamento*", a compreensão acontece de forma instantânea e aparentemente sem esforço.

4. A Hierarquia da Compreensão

Em frações de segundo, o cérebro identifica as palavras, reconhece suas classes gramaticais, constrói a estrutura da oração, interpreta o significado e — o mais sofisticado de tudo — percebe que "*não resistiu*" é um eufemismo para morte, não uma descrição literal de fraqueza física.

4.1. Nível 1 — Morfológico: o que são as palavras?

O que são as unidades do texto?

No PLN, o nível morfológico engloba as operações que **transformam texto bruto em unidades analisáveis**.

4.1. Nível 1 — Morfológico: o que são as palavras?

- **Tokenização**: dividir o texto contínuo em unidades chamadas tokens.
- **Análise morfológica**: identifica a estrutura interna de cada palavra.
- **Stemming e lematização**: são duas operações que reduzem variações morfológicas.
- **POS Tagging**: marcação morfossintática — atribui a cada token sua classe gramatical: substantivo, verbo, adjetivo, advérbio, preposição.

4.2. Nível 2 — Sintático: como as palavras se relacionam?

Agora, como essas palavras se combinam para formar uma estrutura gramatical?

Saber que uma frase contém um **substantivo**, um **verbo** e um **adjetivo** não é suficiente para entender o que ela diz — é preciso **saber quais palavras se relacionam com quais, e de que forma.**

4.2. Nível 2 — Sintático: como as palavras se relacionam?

No PLN, o nível sintático se concretiza em duas grandes abordagens complementares:

- **Análise de constituição**
- **Análise de dependências**


4.2. Nível 2 — Sintático: como as palavras se relacionam?

A análise de constituição

Uma frase como "*o modelo neural classificou os textos rapidamente*" é decomposta em um **sintagma nominal** (o modelo neural), um **sintagma verbal** (classificou os textos rapidamente), e assim recursivamente, até chegar às palavras individuais.

O resultado é uma árvore sintática que mostra como os grupos se encaixam uns dentro dos outros.

4.2. Nível 2 — Sintático: como as palavras se relacionam?



4.2. Nível 2 — Sintático: como as palavras se relacionam?


A análise de dependências

em vez de identificar grupos, ela identifica relações binárias entre palavras. Cada palavra — exceto o verbo principal — depende de outra, e essa dependência recebe um rótulo que descreve a relação gramatical.

Em "*o modelo classificou os textos*", "*modelo*" é o sujeito de "*classificou*", "*textos*" é o objeto direto de "*classificou*" e "*o*" é o determinante de "*modelo*".

O resultado é uma árvore de dependências que mapeia explicitamente quem faz o quê para quem.

4.2. Nível 2 — Sintático: como as palavras se relacionam?



4.2. Nível 2 — Sintático: como as palavras se relacionam?

chunking

Em vez de construir a árvore sintática completa, identifica apenas os sintagmas principais — nominais, verbais, preposicionais — sem analisar a estrutura interna de cada um. É computacionalmente mais eficiente e suficiente para muitas aplicações.

4.3. Nível 3 — Semântico: o que as palavras e frases significam?

O que o texto realmente quer dizer? Este é o nível onde a linguagem deixa de ser uma estrutura formal e se torna um veículo de significado — e onde os maiores desafios computacionais do PLN se concentram.

4.3. Nível 3 — Semântico: o que as palavras e frases significam?

- Semântica lexical
- Representações vetoriais de significado
- Papéis semânticos
- Reconhecimento de entidades nomeadas (**NER**)
- Análise de sentimento

4.3. Nível 3 — Semântico: o que as palavras e frases significam?

Semântica lexical estuda o significado das palavras individuais e as relações entre elas. Aqui residem a **polissemia** — uma palavra com múltiplos significados relacionados — e a **homonímia** — palavras com formas idênticas mas significados completamente distintos. "Banco" é homônimo; "cabeça" (parte do corpo, líder, topo de uma lista) é polissêmica.

4.3. Nível 3 — Semântico: o que as palavras e frases significam?

Representações vetoriais de significado são a maior contribuição do aprendizado de máquina ao nível semântico. Em vez de representar o significado de uma palavra por uma definição ou por sua posição em uma taxonomia, os **word embeddings** representam o significado como um vetor de números reais em um espaço de alta dimensão.

4.3. Nível 3 — Semântico: o que as palavras e frases significam?

Papéis semânticos identificam a função que cada constituinte da frase exerce em relação ao evento descrito pelo verbo. Na frase "*o vírus destruiu o arquivo*", "*vírus*" é o **agente** (quem realiza a ação), "*arquivo*" é o **paciente** (quem sofre a ação) e "*destruiu*" é o **predicado**.

4.3. Nível 3 — Semântico: o que as palavras e frases significam?

Reconhecimento de entidades nomeadas (NER) identifica e classifica sequências de *tokens* que se referem a entidades específicas no mundo: pessoas, organizações, locais, datas, valores monetários, produtos.

4.3. Nível 3 — Semântico: o que as palavras e frases significam?

Análise de sentimento determina a orientação afetiva de um texto — **positivo, negativo ou neutro** — e pode se aprofundar até o nível de aspecto: não apenas "esta avaliação é negativa", mas "a câmera recebeu avaliação positiva, mas a bateria recebeu avaliação negativa".

4.4. Nível 4 — Discursivo: como as sentenças se conectam?

Os três primeiros níveis analisam a linguagem sentença por sentença. Mas a comunicação humana raramente acontece em sentenças isoladas — ela acontece em **textos, conversas, narrativas, argumentos.**

4.4. Nível 4 — Discursivo: como as sentenças se conectam?

- Resolução de correferência
- Coerência e coesão
- Estrutura retórica e argumentativa
- Gerenciamento de diálogo

4.4. Nível 4 — Discursivo: como as sentenças se conectam?

Resolução de correferência identifica quais expressões ao longo do texto se referem ao mesmo objeto ou entidade no mundo.

Coerência e coesão são as propriedades que fazem um conjunto de sentenças ser percebido como um texto e não como uma lista aleatória de frases.

4.4. Nível 4 — Discursivo: como as sentenças se conectam?

Estrutura retórica e argumentativa organiza os textos segundo as relações lógicas e argumentativas entre suas partes.

Gerenciamento de diálogo é a forma que o nível discursivo assume em conversações. Um chatbot ou assistente virtual não apenas processa sentenças individuais — ele mantém um **estado da conversa**, rastreia o que foi dito anteriormente, identifica quando o usuário muda de assunto, reconhece atos de fala como pedidos, confirmações e rejeições, e usa todo esse **contexto** para gerar respostas coerentes com o histórico da interação.

4.5. Nível 5 - Aplicado: como o conhecimento linguístico resolve problemas reais?

Aqui é onde o conhecimento dos níveis anteriores se transformam em produtos, sistemas e soluções que resolvem problemas reais para usuários reais. É o nível onde o PLN encontra o mundo.

4.5. Nível 5 - Aplicado: como o conhecimento linguístico resolve problemas reais?

- Tradução automática
- Sumarização automática
- Análise de sentimento e opinião
- Recuperação de informação e busca semântica
- Sistemas de perguntas e respostas (QA)
- Modelos de linguagem grandes (LLMs)

Cada técnica que você aprenderá nas próximas semanas se encaixa em algum ponto desta hierarquia.

- O *pré-processamento* e o *POS tagging* pertencem ao nível **morfológico**.
- O *parsing* e o *chunking* pertencem ao nível **sintático**.
- Os *word embeddings*, o *NER* e a *análise de sentimento* pertencem ao nível **semântico**.
- Os *sistemas de diálogo* e a *resolução de correferência* pertencem ao nível **discursivo**.
- A *tradução*, a *sumarização*, os *chatbots* e os *LLMs* pertencem ao nível **aplicado**.

5. As Três Eras do Processamento de Linguagem Natural

A história do PLN não é uma linha reta de progresso contínuo. É uma narrativa de apostas intelectuais, fracassos reveladores e reviravoltas inesperadas — cada uma delas ensinando algo fundamental sobre a natureza da linguagem e sobre os limites do que é computável.

A Evolução do Raciocínio Computacional

Era 1 (1950-1990): Sistemas Baseados em Regras




Filosofia: SE... ENTÃO. Tentar programar toda a gramática humana.
Marco: O chatbot ELIZA (1966). Falhou pela impossibilidade de mapear todas as exceções da linguagem.

Era 2 (1990-2012): Modelos Estatísticos



Filosofia: Probabilidade. Aprender padrões contando a frequência das palavras.
Marco: Google Translate original. Dados em quantidade superam regras em qualidade.

Era 3 (2012-Presente): Deep Learning & Transformers



Filosofia: Representações neurais e atenção global.
Marco: ChatGPT, Claude. A revolução dos Grandes Modelos de Linguagem (LLMs).

5.1. Era 1 — Sistemas Baseados em Regras (1950–1990)

A primeira era nasceu de um otimismo genuíno e logicamente fundamentado. Se a linguagem tem gramática, e gramática é um conjunto de regras, então seria possível — e talvez não muito difícil — escrever essas regras e fazer os computadores as seguirem.

5.1. Era 1 — Sistemas Baseados em Regras (1950–1990)

Os primeiros *chatbots*, como o **ELIZA** (1966), simulavam conversas por meio de padrões de substituição de texto.

Os resultados eram impressionantes em ambientes controlados e domínios fechados. **O problema era a escala.**

5.2. Era 2 — Modelos Estatísticos (1990–2012)

A segunda era nasceu de uma mudança de pergunta. Em vez de perguntar "*como codificamos as regras da linguagem?*", os pesquisadores começaram a perguntar "*o que os dados nos dizem sobre como a linguagem funciona?*".

5.2. Era 2 — Modelos Estatísticos (1990–2012)

A ideia central era elegante na sua simplicidade: se em milhões de textos reais certas sequências de palavras aparecem juntas com muito mais frequência do que outras, então a frequência é um proxy do que é linguisticamente natural.

5.2. Era 2 — Modelos Estatísticos (1990–2012)

Um modelo que aprende essas frequências aprende, indiretamente, algo sobre a gramática e o uso da língua — sem que ninguém precise escrever uma única regra.

5.3. Era 3 — Deep Learning e Transformers (2012–presente)

Em 2013, o **Word2Vec** demonstrou que palavras podiam ser representadas como **vetores densos** em um espaço de significado, onde **proximidade geométrica correspondia a similaridade semântica**.

5.3. Era 3 — Deep Learning e Transformers (2012–presente)

Em 2017, o artigo "*Attention Is All You Need*", publicado por pesquisadores do Google Brain, introduziu a arquitetura **Transformer** — um mecanismo que permitia a cada token de uma sequência considerar simultaneamente todos os outros tokens, eliminando a limitação de contexto local que havia constrangido todas as arquiteturas anteriores.

5.3. Era 3 — Deep Learning e Transformers (2012–presente)

Em 2018, o **BERT** demonstrou que **modelos pré-treinados em grandes corpora** podiam ser ajustados para **tarefas específicas com poucos exemplos** e resultados superiores ao estado da arte em onze benchmarks simultâneos.

5.3. Era 3 — Deep Learning e Transformers (2012–presente)

Em 2020, o **GPT-3** mostrou que modelos suficientemente grandes conseguiam realizar tarefas para as quais não foram explicitamente treinados, apenas com a descrição da tarefa no *prompt*.

5.3. Era 3 — Deep Learning e Transformers (2012–presente)


Em 2022, o **ChatGPT** colocou essas capacidades nas mãos de cem milhões de usuários em dois meses — o crescimento mais rápido na história de qualquer aplicação.

5.3. Era 3 — Deep Learning e Transformers (2012–presente)


Os modelos modernos aprendem implicitamente morfologia, sintaxe, semântica e estrutura discursiva sem que os engenheiros precisem codificar nenhum desses níveis manualmente

Quando o Significado Virou Geometria

A Revolução do Word2Vec (2013)



Palavras não são mais textos, mas **coordenadas** em um **espaço multidimensional**.
Palavras com significados **similares** habitam **regiões próximas**. As **relações semânticas** tornaram-se operações aritméticas puras.



Em 2013, paramos de tentar ensinar a definição das palavras e permitimos que a máquina calculasse a geometria das relações

A Verdade Sobre os LLMs

Modelos como o ChatGPT (arquitetura Transformer) não entendem o que dizem da mesma forma que os humanos. Eles não pensam; eles calculam.



Probabilidade da Próxima Palavra

[Brasília] -> 98.4%

[Rio] -> 1.2%

[bonita] -> 0.3%

PLN moderno não é magia intelectual. É o aprendizado de **distribuições de probabilidade** sobre sequências de tokens em uma escala de trilhões de dados.


A roda da complexidade: por que as máquinas ainda falham

Lexical (Polissemia) -
Uma palavra,
mútiplos mundos

Sintática (Estrutural)
- A arquitetura
invisível da frase

Discursiva
(Correferência) -
A teia de pronomes
e memória

Pragmática
(Conhecimento) -
Ironia, sarcasmo
e o que não é dito



O Muro da Complexidade Humana



Ambiguidade Lexical

Visitei o banco ontem (Homonímia).
Instituição financeira ou assento de
praça? Depende exclusivamente do
contexto ausentado.



Correferência (Teste de Winograd)

O troféu não cabia na mala porque era
grande demais. O que era grande? A
A resolução exige física básica (malas
contêm troféus), não apenas gramática.



Ironia e Sarcasmo

Que dia lindo! (Dito durante uma
enchente). Modelos ingênuos de Análise
de Sentimento classificam como 100%
positivo, ignorando a pragmática.



Variação Sociolinguística

Não possuo recursos vs. Tô teso vs. Zero
na conta. A mesma intenção semântica
dispersa em infinitos registros culturais.

6. Línguas de Baixo Recurso

Quando o *GPT-4* foi lançado em 2023, pesquisadores ao redor do mundo testaram suas capacidades em dezenas de idiomas. Os resultados foram reveladores — não pelo que o modelo conseguia fazer, mas pelo que ele evidenciava sobre quem **havia sido deixado para trás**.

O Desafio Ético: Línguas de Baixo Recurso

O progresso em PLN é distribuído de forma radicalmente desigual.

Top 10 Línguas (Inglês, etc.) - Representação Massiva

Outras 6.900+ Línguas - Representação Mínima

7.000

línguas vivas no mundo.

< 100

idiomas cobertos por modelos de alta qualidade.

95%

da pesquisa global concentrada nas 10 línguas mais ricas.

No Brasil, temos cerca de 180 línguas indígenas (como Tupinambá e Guarani) com **representação** computacional mínima. O foco exclusivo no inglês aprofunda desigualdades tecnológicas.

6. Línguas de Baixo Recurso

Em inglês, o modelo redigia ensaios acadêmicos, depurava código, explicava conceitos científicos complexos e conduzia conversas filosoficamente sofisticadas.

Em português, francês, alemão, espanhol e mandarim, o desempenho era notavelmente bom.

6. Línguas de Baixo Recurso

Em turco e swahili, havia degradação perceptível.

Em yorùbá, hauçá e amárico, a qualidade caía de forma abrupta.

6. Línguas de Baixo Recurso

Em guarani, tucano, krenak ou mbyá-guarani, o modelo simplesmente não funcionava — não porque os engenheiros tenham tomado uma decisão deliberada de excluí-los, mas porque **esses idiomas quase não existem nos dados com os quais o modelo foi treinado.**

6. Línguas de Baixo Recurso

O termo **língua de baixo recurso** refere-se a idiomas para os quais existe escassez de recursos computacionais e linguísticos digitais. Esses recursos incluem corpora textuais anotados, dicionários eletrônicos, bases de dados lexicais, ferramentas de tokenização e lematização treinadas no idioma, modelos de linguagem disponíveis publicamente e benchmarks de avaliação padronizados.

6. Línguas de Baixo Recurso

O português brasileiro é, no contexto global do PLN, um idioma relativamente privilegiado. Existem modelos de linguagem treinados especificamente para o português, como o **BERTimbau** desenvolvido pelo NLP-USP, e corpora significativos como o **Bosque**, o **Mac-Morpho** e o **corpus do Tribunal Superior Eleitoral**.

6. Línguas de Baixo Recurso

Ainda assim, mesmo o português permanece em desvantagem considerável em relação ao inglês — modelos multilíngues como o **mBERT** ou o **XLNet** têm desempenho consistentemente inferior em português quando comparado ao inglês nas mesmas tarefas.

7. Da teoria ao código

Ao longo desta aula percorremos um caminho inteiramente conceitual. Compreendemos o que é linguagem, o que a torna natural, por que 80% dos dados do mundo são não estruturados, como as três eras do PLN se sucederam, quais são os níveis da hierarquia da compreensão e por que a desigualdade entre idiomas é um problema ético e não apenas técnico.

7. Da teoria ao código

O objetivo desta seção prática não é que você memorize comandos. É que você desenvolva a intuição de como texto se transforma em dado — e por que essa transformação importa.

Da Teoria ao Código (Google Colab)

A abordagem ingênua - Python nativo

```
> texto = "PLN é incrível!"  
> tokens = texto.split()  
> Resultado: ['PLN', 'é', 'incrível!']
```



**Erro: Pontuação
grudada na palavra**

A abordagem profissional - NLTK

```
> from nltk.tokenize import word_tokenize  
> tokens = word_tokenize(texto)  
> Resultado: ['PLN', 'é', 'incrível', '!']
```



**O algoritmo isola a
pontuação como um token
semântico independente**

7.1. A Abordagem Ingênua — Tokenização com split()

Primeiro problema real de PLN que vamos atacar com código: **tokenização**.

Tokenizar é dividir um texto contínuo em unidades menores chamadas **tokens**. É a porta de entrada de qualquer pipeline de PLN — **sem tokens, não há o que analisar**.

7.1. A Abordagem Ingênua — Tokenização com `split()`

A abordagem mais imediata que qualquer programador tentaria é usar o método **`split()`**, nativo do Python.

A lógica é intuitiva: se as palavras são separadas por espaços, basta dividir o texto onde há espaços.

7.1. A Abordagem Ingênua — Tokenização com split()

```
frase = "O processamento de linguagem natural é fascinante"  
tokens = frase.split()  
print(tokens)  
print(f"Total de tokens: {len(tokens)}")
```


7.1. A Abordagem Ingênua — Tokenização com split()

Para esse exemplo específico, funciona perfeitamente. O problema começa quando o texto se aproxima da realidade.

7.1. A Abordagem Ingênua — Tokenização com split()

```
frase_real = "PLN é incrível! Mas também é desafiador, não é mesmo?"  
tokens_raw = frase_real.split()  
print(tokens_raw)
```

7.1. A Abordagem Ingênua — Tokenização com split()

Você pode tentar corrigir o problema com uma expressão regular:

```
import re
```

```
tokens_regex = re.findall(r'\b\w+\b', frase_real.lower())
```

```
print(tokens_regex)
```


7.1. A Abordagem Ingênua — Tokenização com split()

Isso já é melhor — a pontuação some e as palavras ficam em minúsculas. Mas agora surgem novos problemas. Contrações e hífen são tratados de forma inconsistente.

7.1. A Abordagem Ingênua — Tokenização com split()

Abreviações como "*Dr.*" perdem o ponto e ficam indistinguíveis de palavras comuns. Valores como "*R\$ 4.200*" se fragmentam de formas imprevisíveis. E o mais importante: você está escrevendo regras manualmente — **o exato paradigma que a segunda e a terceira era do PLN superaram!**

7.2. A Abordagem Profissional — Tokenização com NLTK

O **Natural Language Toolkit — NLTK** — é a biblioteca de PLN mais clássica e pedagogicamente rica disponível para Python. Criada em 2001 na Universidade da Pensilvânia por Steven Bird e Edward Loper, ela foi concebida especificamente para o **ensino e a pesquisa em linguística computacional**.

7.2. A Abordagem Profissional — Tokenização com NLTK

Ao longo de mais de duas décadas, tornou-se a referência padrão para quem está aprendendo PLN — exatamente pelo mesmo motivo que ela é ideal para esta aula: **ela torna visível o que está acontecendo, em vez de esconder tudo dentro de uma caixa preta.**

7.2. A Abordagem Profissional — Tokenização com NLTK

No Colab, o NLTK já vem instalado por padrão, mas é necessário baixar os recursos específicos que usaremos.

```
import nltk  
  
nltk.download('punkt', quiet=True)  
nltk.download('punkt_tab', quiet=True)  
nltk.download('stopwords', quiet=True)
```

7.2. A Abordagem Profissional — Tokenização com NLTK

O argumento **quiet=True** suprime as mensagens de progresso, mantendo o notebook limpo.

Os recursos baixados são três:

- **punkt** é o modelo de tokenização treinado em corpus real;
- **punkt_tab** é uma atualização recente necessária em versões mais novas do NLTK;
- e **stopwords** é a lista de palavras de parada em múltiplos idiomas, que usaremos em seguida.

7.2. A Abordagem Profissional — Tokenização com NLTK

Com os recursos carregados, importe as funções que usará:

```
from nltk.tokenize import word_tokenize, sent_tokenize
```

```
from nltk.corpus import stopwords
```

7.2. A Abordagem Profissional — Tokenização com NLTK

Agora aplique o tokenizador de palavras à mesma frase problemática que usou com o `split()`:

```
frase_real = "PLN é incrível! Mas também é desafiador, não é mesmo?"
```

```
tokens_nltk = word_tokenize(frase_real, language='portuguese')
```

```
print(tokens_nltk)
```

```
print(f"Total de tokens: {len(tokens_nltk)}")
```

7.2. A Abordagem Profissional — Tokenização com NLTK

O parâmetro **language='portuguese'** é crucial. O tokenizador **punkt** é um modelo estatístico treinado em corpus real de cada idioma, e ele aprendeu os padrões específicos de **como o português usa pontuação, abreviações e contrações.**

7.2. A Abordagem Profissional — Tokenização com NLTK

Sem esse parâmetro, o NLTK usa o modelo padrão em inglês, que toma decisões erradas em textos em português — especialmente com abreviações como "*Sr.*", "*Dra.*" e "*etc.*" que terminam com ponto.

7.2. A Abordagem Profissional — Tokenização com NLTK

```
texto_complexo = (  
    "Dr. Silva prescreveu 500mg de ibuprofeno às 8h. "  
    "O Sr. João pagou R$ 42,50 na farmácia. "  
    "Ele perguntou: 'Isso é suficiente?' A Dra. Ana confirmou.“  
)  
tokens_complexos = word_tokenize(texto_complexo, language='portuguese')  
print(tokens_complexos)
```

7.2. A Abordagem Profissional — Tokenização com NLTK

Tokenização de sentenças

Além de dividir o texto em palavras, muitas aplicações precisam primeiro dividir o texto em sentenças — o que em PLN se chama de *sentence splitting* ou *tokenização de sentenças*.

7.2. A Abordagem Profissional — Tokenização com NLTK

Tokenização de sentenças

Intuitivamente, parece simples: basta dividir onde há ponto final. Mas você já viu que "*Dr.*" e "*Dra.*" contêm pontos que não marcam fim de sentença — e existem dezenas de casos similares.

7.2. A Abordagem Profissional — Tokenização com NLTK

O NLTK resolve esse problema com o **sent_tokenize**:

7.2. A Abordagem Profissional — Tokenização com NLTK

```
texto_longo = (  
    "O Prof. Anderson iniciou a aula às 8h. "  
    "Ele explicou que o PLN tem três eras históricas. "  
    "A 1ª era foi baseada em regras, a 2ª em estatística. "  
    "A 3ª era, iniciada em 2012, é dominada pelo deep learning."  
)  
  
sentencas = sent_tokenize(texto_longo, language='portuguese')  
  
print(f"Total de sentenças: {len(sentencas)}")  
  
for i, s in enumerate(sentencas, 1):  
    print(f" [{i}] {s}")
```

7.2. A Abordagem Profissional — Tokenização com NLTK

Compare o resultado com o que você obteria dividindo ingenuamente por ponto:

```
sentencas_ingenuas = texto_longo.split('.')  
  
print(f"\nDivisão ingênua por ponto: {len(sentencas_ingenuas)} partes")  
  
for i, s in enumerate(sentencas_ingenuas, 1):  
    print(f"    [{i}] {s.strip()}")
```

7.3. Analisando frequências — o que o texto revela sobre si mesmo

Com os tokens em mãos, é possível fazer uma das análises mais simples e reveladoras em PLN: **contar a frequência das palavras.**

Essa análise, aparentemente trivial, é a base de técnicas muito mais sofisticadas como o ***TF-IDF***, que estudaremos na Semana 4

7.3. Analisando frequências — o que o texto revela sobre si mesmo

```
texto_analise = """
```

```
O processamento de linguagem natural é uma das áreas mais fascinantes da inteligência artificial. PLN permite que computadores compreendam, interpretem e gerem linguagem humana. As aplicações de PLN incluem tradução automática, análise de sentimento, reconhecimento de entidades e sistemas de perguntas e respostas. A linguagem humana é rica, ambígua e profundamente contextual. Por isso, PLN é um campo desafiador e em constante evolução. Pesquisadores de todo o mundo trabalham para tornar os sistemas de PLN mais precisos, mais robustos e mais inclusivos.
```

```
"""
```


7.3. Analisando frequências — o que o texto revela sobre si mesmo

Tokenize e converta para minúsculas — a normalização de caixa é necessária para que "PLN" e "pln" sejam contados como a mesma palavra:

```
tokens = word_tokenize(texto_analise.lower(), language='portuguese')  
print(f"Total de tokens brutos: {len(tokens)}")
```

7.3. Analisando frequências — o que o texto revela sobre si mesmo

Você perceberá que o total inclui pontuação e palavras como "a", "de", "e", "o" — elementos que aparecem muitas vezes mas dizem pouco sobre o tema do texto. Para uma análise significativa, é preciso filtrá-los. Aqui entram as ***stopwords***:

7.3. Analisando frequências — o que o texto revela sobre si mesmo

```
import string

stop_pt = set(stopwords.words('portuguese'))

tokens_limpos = [
    token for token in tokens
    if token not in stop_pt          # não é stopword
    and token not in string.punctuation # não é pontuação
    and token.isalpha()             # apenas letras, sem números ou símbolos
    and len(token) > 2              # comprimento mínimo de 3 caracteres
]

print(f"Tokens após limpeza: {len(tokens_limpos)}")
print(f"Redução: {(1 - len(tokens_limpos)/len(tokens))*100:.1f}% dos tokens removidos")
print(f"\nTokens relevantes: {tokens_limpos}")
```


7.3. Analisando frequências — o que o texto revela sobre si mesmo

Observe a taxa de redução. Em textos típicos em português, entre 50% e 70% dos tokens são removidos nessa etapa — e o que sobra é exatamente o vocabulário que carrega o conteúdo temático do texto.

Agora calcule as frequências usando o **FreqDist** do NLTK — uma estrutura de dados especializada em distribuições de frequência:

7.3. Analisando frequências — o que o texto revela sobre si mesmo

```
from nltk.probability import FreqDist

freq = FreqDist(tokens_limpos)

print("Palavras mais frequentes:")
for palavra, contagem in freq.most_common(10):
    barra = "█" * contagem
    print(f"  {palavra:<20} {contagem:>2}  {barra}")
```

7.3. Analisando frequências — o que o texto revela sobre si mesmo

A visualização em barra de caracteres é simples mas imediatamente informativa. As palavras mais frequentes revelam o tema central do texto — e você perceberá que "*pln*", "*linguagem*" e "*sistemas*" dominam a lista, exatamente as palavras que identificariam esse texto como pertencente ao domínio do processamento de linguagem natural.

O Profissional Além da Caixa-Preta

Fundamentos

LLMs são caixas-pretas. Sem entender tokenização, embeddings e arquitetura de Transformers, o desenvolvedor torna-se refém da API.

Diagnóstico

Quando o modelo alucina ou falha em uma ambiguidade, o conhecimento das raízes do PLN é o que permite depurar o erro.

Valor de Mercado

Profissionais de IA que dominam a matemática por trás da magia recebem, em média, 38% a mais que usuários apenas operacionais.

PLN não é sobre criar máquinas que pensem. É sobre criar máquinas que consigam espelhar, calcular e processar a complexidade do pensamento humano.

Referências

CASELI, H. M.; NUNES, M. G. V. (org.). Processamento de linguagem natural: conceitos, técnicas e aplicações em português. São Carlos: BPLN, 2023. Cap. 1, pp. 1–28; Cap. 3, pp. 53–84; Cap. 4, pp. 85–120.

FACELI, K. et al. Inteligência Artificial: uma abordagem de aprendizado de máquina. Rio de Janeiro: LTC, 2025. Cap. 1; Cap. 12, pp. 229–266; Cap. 13, pp. 267–302.

SUMATHI, S.; JANANI, M. Neural Networks for Natural Language Processing. Hershey, PA: Engineering Science Reference, 2020. Cap. 1, pp. 1–27; Cap. 6, pp. 173–214.

MARTINS, J. S. et al. Processamento de Linguagem Natural. Porto Alegre: Grupo A, 2024. Cap. 1, pp. 1–22; Cap. 2, pp. 23–48; Cap. 3, pp. 49–72.

NETTO, A.; MACIEL, F. Python para Data Science e Machine Learning Descomplicado. Rio de Janeiro: Alta Books, 2021. Cap. 5, pp. 87–114.



IBMEC.BR

 /IBMEC

 IBMEC

 @IBMEC_OFICIAL

 @IBMEC

 **ibmec**