


Aula 02

Pré-processamento de texto

PROCESSAMENTO DE LINGUAGEM NATURAL - IBM3130

Prof. Anderson Vanin



1. Introdução

Antes de treinar qualquer modelo, você precisa transformar o caos textual em uma **representação limpa, padronizada e comparável**.

Esse processo de preparação é o **pré-processamento de texto** — e ele é a etapa que mais influencia a qualidade final de qualquer sistema de PLN

Como humanos leem

Produto **INCRÍVEL!!**
Chegou em 2 dias.
Super satisfeita c/
a entrega :)
MAS embalagem
amassada...

Ênfase visual

Informalidade

Emoção



O que a máquina vê

Produto **INCRÍVEL!!**
Chegou em **2 dias**
Super satisfeita c/a
entrega
MAS
embalagem
amassada




O modelo de IA não consegue processar a análise sem antes lavar, descascar e fatiar a linguagem bruta.

1.1 Pipeline

Um pipeline de pré-processamento de texto é uma **sequência ordenada e composta de transformações aplicadas a textos brutos** com o objetivo de produzir **representações limpas, padronizadas e adequadas para as etapas subsequentes** de análise ou modelagem.

Em projetos profissionais de PLN, o pipeline de pré-processamento é frequentemente empacotado como uma função ou classe reutilizável.

1.2 As cinco etapas e a lógica da sequência



1.2 As cinco etapas e a lógica da sequência

Ordem	Etapa	Problema resolvido	Entrega para a próxima
1ª	Tokenização	Texto contínuo não tem unidades claras para processar	Sequência de tokens (unidades mínimas)
2ª	Lowercase	Mesma palavra em formas diferentes = tokens distintos	Tokens padronizados em caixa baixa
3ª	Limpeza de ruído	URLs, e-mails, emojis e símbolos não carregam significado	Tokens puramente textuais e relevantes
4ª	Remoção de stopwords	Palavras funcionais dominam a frequência sem discriminar temas	Vocabulário de conteúdo semântico denso
5ª	Stemming/Lematização	Variações morfológicas fragmentam o mesmo conceito	Formas canônicas que agrupam variantes

1.3 A transformação passo a passo

Texto Bruto:

"HORRÍVEL!! O produto chegou QUEBRADO e o atendimento foi péssimo!!! Nunca mais compro nessa loja. Acesse: reclamação.site/12345"

1.3 A transformação passo a passo

Após tokenização:

['HORRÍVEL', '!', '!', 'O', 'produto', 'chegou', 'QUEBRADO', 'e', 'o', 'atendimento', 'foi', 'péssimo', '!', '!', '!', 'Nunca', 'mais', 'compro', 'nessa', 'loja', '.', 'Acesse', ':', 'reclamação.site/12345']

1.3 A transformação passo a passo

Após lowercase:

['horrível', '!', '!', 'o', 'produto', 'chegou',
'quebrado', 'e', 'o', 'atendimento', 'foi', 'péssimo',
'!', '!', '!', 'nunca', 'mais', 'compro', 'nessa', 'loja',
'.', 'acesse', ':', 'reclamação.site/12345']

1.3 A transformação passo a passo

Após limpeza:

['horrível', 'produto', 'chegou', 'quebrado',
'atendimento', 'foi', 'péssimo', 'nunca', 'mais',
'compro', 'nessa', 'loja', 'acesse']

1.3 A transformação passo a passo

Após remover stopwords:


['horrível', 'produto', 'chegou', 'quebrado',
'atendimento', 'péssimo', 'nunca', 'mais',
'compro', 'loja']

1.3 A transformação passo a passo

Após stemming (RSLP):

['horrívelr', 'produt', 'cheg', 'quebr', 'atendimento',
'péssim', 'nunca', 'mais', 'compr', 'loj']

1.4 A ordem do pipeline não é negociável!



1.5 O pipeline como decisão de projeto

Uma última reflexão sobre o pipeline antes de entrar nos detalhes de cada etapa: o pipeline não é universal. Não existe um conjunto fixo de etapas que funciona para todos os projetos de PLN.

1.5 O pipeline como decisão de projeto

A escolha de quais etapas incluir, em que ordem e com quais parâmetros depende fundamentalmente de três fatores:

- Tarefa
- Domínio
- Modelo

Estação 1: Tokenização (A Porta de Entrada)



Split (Ingênuo)

- **Ferramenta:** ".split()"
- **Mecanismo:** Corta por espaços em branco.
- **Problema:** Pontuação gruda (ex: 'fácil!').

Regex (Manual)

- **Ferramenta:** re.findall()
- **Mecanismo:** Regras de texto padronizadas.
- **Uso Ideal:** Domínios com notações específicas (ex: R\$, dados médicos).

Modelos (Padrão Industrial)

- **Ferramentas:** NLTK (word_tokenize) e spaCy
- **Mecanismo:** Treinado em dados reais, isola a pontuação via contexto.

Subpalavras (LLMs)

- **Ferramentas:** BERT / GPT
- **Mecanismo:** Corta palavras raras em sílabas. Nunca encontra tokens desconhecidos.

A Ilusão do Ponto Final (Sentence Splitting)


O Dr. Silva trabalha no Depto. da USP.

A Tesoura Burra




O método de split comum fragmenta a frase em abreviações.

O Scanner Contextual



Modelos treinados (como NLTK punkt) reconhecem abreviações e mantêm a integridade da sentença

Estação 2: O Poder e o Perigo do *Lowercase*



Padronização drástica:
Evita a contagem triplicada da mesma palavra, reduzindo a dimensionalidade artificial.

Quando NÃO aplicar Lowercase


- | | |
|------------------------------------|---|
| • Entidades Nomeadas (NER): | → Diferencia "Apple" (Empresa) de "apple" (Fruta). |
| • Análise de Sentimento: | → "ÓTIMO!!!" expressa uma intensidade ausente em "ótimo". |
| • Siglas: | → "PLN" ou "CPU" em minúsculas podem ser confundidas com ruído. |

Estação 3: Remoção de Ruído

A Regra de Ouro: Esta informação é relevante para a MINHA tarefa?

The Algorithmic Sieve

Acesse <https://site.com> ou mande e-mail para ola@empresa.com.br 🔥 (11) 9999-0000.



Estação 4: Stopwords (Eliminando o Peso Morto)

[o][o] **governo** [[]]

[de] [**economia**]

[que] **crescimento**

[em [a] **juros** [é]

A remoção do "ruído de fundo" reduz o vocabulário em até 60%, acelerando cálculos e revelando o verdadeiro sinal semântico.



Stopwords Customizadas

Em um corpus de laudos médicos, a palavra 'paciente' aparece em 100% dos textos.

Por não ter valor discriminativo, ela se torna **ruído** e deve ser adicionada à lista de stopwords daquele domínio específico.

A Armadilha: O Efeito de Sentimento Invertido

Step 1: Input Box

Não gostei
do produto.

Step 2: Processing Filter (Filtro Padrão de Stopwords)

~~Não~~
[gostei]
[produto]
~~do~~

Step 3: The Disaster (The Dial)



Ao remover o "Não", o sentido da frase
é completamente invertido.

A Correção: Em análise de sentimento, conectivos de negação são a alma do texto.

```
stops -= {'não', 'nunca', 'jamais'}
```


Estação 5: O Confronto Morfológico

Stemming (ex: RSLP do NLTK)



Mecanismo

Corta sufixos cegamente por regras heurísticas. Altíssima velocidade.

Resultado

Gera um 'Radical' (frequentemente NÃO é uma palavra válida).

[correndo] -> [corr]

Lematização (ex: spaCy)



Mecanismo

Usa análise gramatical e léxico real da língua. Mais pesado computacionalmente.

Resultado


Gera um 'Lema' (sempre uma forma canônica do dicionário).

[correndo] -> [correr]

[melhores] -> [bom] (Reconhece irregulares!)


A Patologia do Stemming: O Espectro da Redução

Corte Profundo Demais (Overstemming)



Homonímia forçada: O machado agrupa conceitos com significados completamente distintos.

Corte Insuficiente (Understemming)



Desconhecimento de léxico: O algoritmo ignora a relação de superlativos irregulares.

O Raio-X do Lematizador: 0 Fator Contextual

Contexto de Entrada:

Cheguei muito cedo.



Machine Detection
(POS Box)

ADVÉRBIO

Saída Final:

Lema = cedo

Contexto de Entrada:

Eu cedo meu lugar.

Machine Detection
(POS Box)

VERBO

Saída Final:


Lema = **ceder**

Sem análise **morfossintática** (POS Tagging), não existe lematização correta.
Ferramentas de produção rodam essas análises simultaneamente.


1.6 Atributos essenciais do objeto Token

O objeto **Token** é a unidade fundamental de análise no **spaCy**. Cada token possui dezenas de atributos — alguns calculados pelo pipeline, outros inferidos das regras do modelo.

1.6 Atributos essenciais do objeto Token



1.7 Mapa de Decisões Finais



Referências

CASELI, H. M.; NUNES, M. G. V. (org.). Processamento de linguagem natural: conceitos, técnicas e aplicações em português. São Carlos: BPLN, 2023. Cap. 3, pp. 53–84.

FACELI, K. et al. Inteligência Artificial: uma abordagem de aprendizado de máquina. Rio de Janeiro: LTC, 2025. Cap. 5, pp. 91–118.



IBMEC.BR

 /IBMEC

 IBMEC

 @IBMEC_OFICIAL

 @IBMEC

 **ibmec**