

Aula 03

Fundamentos Linguísticos — POS Tagging

PROCESSAMENTO DE LINGUAGEM NATURAL - IBM3130

Prof. Anderson Vanin

1.1. O que é Morfologia

Morfologia é o ramo da linguística que estuda a estrutura das palavras: **como são formadas a partir de morfemas (unidades mínimas de significado) e quais categorias gramaticais expressam.**

Em PLN, a análise morfológica automatizada permite:

- Identificar a **classe gramatical** de cada token (POS Tagging)
- Reconhecer **formas flexionadas** do mesmo **lema**
- Extrair **informações de gênero, número, tempo verbal e modo**
- **Resolver ambiguidades** de sentido pelo contexto gramatical

INPUT: RAW DATA STREAM > UNPROCESSED

O processamento de linguagem natural em sistemas modernos exige a decomposição precisa de sequências textuais complexas em unidades fundamentais de significado para permitir a análise semântica e a extração de informações críticas. Sem essa estruturação morfossintática inicial, o texto permanece como um fluxo amorfo de caracteres digitais sem utilidade analítica direta ou capacidade de interpretação automatizada avançada por algoritmos de inteligência artificial e machine learning.

O Caos: Apenas uma sequência de caracteres sem significado estrutural.

A Morfologia Computacional é o motor que transforma texto bruto em dados acionáveis.

OUTPUT: STRUCTURED DATA > SEMANTICALLY TAGGED

O **processamento** de **linguagem** **natural** em **sistemas** **modernos** **exige** a **decomposição** **precisa** de **sequências** **textuais** **complexas** em **unidades** **fundamentais** de **significado** para **permitir** a **análise** **semântica** e a **extração** de **informações** **críticas**. Sem essa **estruturação** **morfossintática** **inicial**, o **texto** **permanece** como um **fluxo** **amorfo** de **caracteres** **digitais** sem **utilidade** **analítica** **direta** ou **capaci** de **interpretação** **automatizada** **avançada** por **algoritmos** de **inteligência** **artificial** e **machine learning**.

A Ordem: Entidades, ações e relações semânticas mapeadas.

1.2. Morfemas

O morfema é a **menor unidade com significado** em uma língua. Palavras são combinações de morfemas. Identificar morfemas ajuda o computador a entender que palavras de aparência muito diferente compartilham a mesma raiz e significado.

[in] + [feliz] + [mente] = infelizmente

(Prefixo/Negação) (Raiz) (Sufixo/Modo)

MORPHOLOGICAL DEPENDENCY DIAGRAM >
ROOT IDENTIFICATION & EXPANSION

→ 1_ - - +



INSIGHT

Modelos bem treinados conectam morfemas à mesma raiz geométrica. Isso reduz o vocabulário necessário, economiza processamento e aumenta a precisão do modelo.

1.2. Morfemas

Palavra	Morfemas	Análise morfológica
infelizmente	in + feliz + mente	prefixo (negação) + raiz + sufixo (modo)
computadores	computador + es	raiz + sufixo (plural masculino)
pré-processamento	pré + process + amento	prefixo + raiz + sufixo nominalizador
desfizeram	des + fiz + eram	prefixo (negação) + raiz irregular + sufixo verbal
pesquisadora	pesquis + ador + a	raiz + sufixo agentivo + sufixo feminino
inteligência	intelig + ência	raiz + sufixo nominalizador de qualidade

1.3. Classes Gramaticais

- Grupos de palavras que compartilham propriedades morfológicas, sintáticas e semânticas.
- A gramática tradicional portuguesa distingue dez classes.
- Os sistemas computacionais modernos usam *tagsets* com dezenas de categorias mais granulares.

1.3. Classes Gramaticais

1. **Substantivo** — nomeia seres, objetos, lugares, sentimentos e conceitos. Exemplos: casa, amor, Brasil, algoritmo.
2. **Artigo** — acompanha o substantivo, indicando gênero e número e determinando se a referência é definida ou indefinida. Exemplos: o, a, um, uma.
3. **Adjetivo** — qualifica ou caracteriza o substantivo, indicando propriedades, estados ou relações. Exemplos: bonito, inteligente, brasileiro, neural.
4. **Numeral** — indica quantidade, ordem, múltiplo ou fração. Exemplos: dois, primeiro, triplo, metade.
5. **Pronome** — substitui ou acompanha o substantivo, indicando as pessoas do discurso e relações de posse, demonstração, interrogação ou relativização. Exemplos: eu, meu, este, que, quem.

1.3. Classes Gramaticais

6. Verbo — exprime ação, estado, processo ou fenômeno, flexionando-se em tempo, modo, número e pessoa. Exemplos: correr, ser, classificou, está.

7. Advérbio — modifica o verbo, o adjetivo ou outro advérbio, indicando circunstâncias de modo, tempo, lugar, intensidade, negação, entre outras. Exemplos: rapidamente, hoje, muito, não.

8. Preposição — liga palavras ou orações, estabelecendo relações de lugar, tempo, causa, posse, meio e outras. Exemplos: de, em, para, com, sobre.

9. Conjunção — liga orações ou termos de mesma função sintática, indicando relações de adição, oposição, causa, condição, tempo e outras. Exemplos: e, mas, porque, embora, quando.

10. Interjeição — expressa emoções, sentimentos ou reações de forma espontânea, funcionando como enunciado completo por si só. Exemplos: Ah!, Uau!, Opa!, Ei!.

1.3. Classes Gramaticais

Vale observar que a gramática moderna e os sistemas computacionais de PLN tratam o artigo como uma subcategoria do determinante (tag DET no Universal Dependencies), e acrescentam categorias que a gramática tradicional não distinguia explicitamente, como a pontuação (PUNCT), os símbolos (SYM) e as partículas (PART). Por isso o tagset UD tem 17 categorias enquanto a gramática tradicional trabalha com 10.

MORFOLOGIA COMPUTACIONAL: O ESPECTRO SEMÂNTICO

NOUN / PROPN (A Matéria-Prima)

Função: Extração de tópicos e entidades (NER).

Google, algoritmo

VERB / AUX (O Motor)

Função: Extração de eventos e relações sujeito-objeto.

classificou, falhou

ADJ (A Avaliação)


Função: O coração da análise de sentimento.

robusto, lento

ADV (O Modificador)

Função: Intensifica ou inverte sentimentos (risco crítico se removido como stopword).

não, muito



1.4. Tagsets — Como as Classes são Codificadas

Um tagset (conjunto de etiquetas) é o inventário de rótulos usados por um sistema de **POS tagging** para categorizar tokens. Vamos estudar os dois mais importantes: o **Penn Treebank (PTB)**, padrão histórico do inglês usado pelo **NLTK**, e o **Universal Dependencies (UD)**, padrão moderno cross-linguístico usado pelo **spaCy**.

Penn Treebank (PTB)

- Motor padrão: **NLTK**
- Tamanho: **48** tags
- Força: Padrão ouro para **Inglês Clássico**; altíssima granularidade para **tempos verbais** (VBD, VBG, VBN).
- Exemplo: **NN** (Noun), **VB** (Verb)

Universal Dependencies (UD)

- Motor padrão: **spaCy**
- Tamanho: **17** tags universais
- Força: Padrão moderno cross-linguístico. A mesma lógica funciona em **Português**, **Inglês** ou **Mandarin**.
- Exemplo: **NOUN**, **VERB**

Trabalha com Português ou sistemas multilíngues modernos?
A arquitetura UD (spaCy) é a escolha definitiva.

1.4.1. Penn Treebank Tagset (PTB) — o padrão do NLTK

Tag PTB	Classe UD equiv.	Exemplo (inglês)	Descrição
NN	NOUN	model, data	Substantivo singular
NNS	NOUN	models, datasets	Substantivo plural
NNP	PROPN	Google, Python	Nome próprio singular
VB	VERB	train, run	Verbo no infinitivo
VBD	VERB	trained, ran	Verbo no passado simples
VBG	VERB	training, running	Gerúndio / particípio presente
VCN	VERB	trained, processed	Particípio passado
VBZ	VERB	trains, runs	Verbo pres. 3ª pessoa sing.
JJ	ADJ	fast, accurate	Adjetivo
JJR	ADJ	faster, more accurate	Adjetivo comparativo
RB	ADV	quickly, not, very	Advérbio
IN	ADP	in, of, for, with	Preposição ou conj. subordinativa
CC	CCONJ	and, or, but	Conjunção coordenativa
DT	DET	the, a, an	Artigo / determinante
PRP	PRON	I, he, she, it	Pronome pessoal
CD	NUM	1, 42, first	Numeral cardinal
MD	AUX	can, will, must	Modal auxiliar

O Penn Treebank é um corpus de inglês anotado desenvolvido na Universidade da Pensilvânia entre 1989 e 1992. Seu tagset de 48 rótulos tornou-se o padrão para inglês. **O NLTK usa PTB por padrão em `pos_tag()`.**

1.4.2. Universal Dependencies (UD) — o padrão do spaCy

Tag UD	PTB equiv.	Exemplo PT	Descrição
NOUN	NN/NNS	cidade, modelo, dado	Substantivo comum
PROPN	NNP/NNPS	São Paulo, Google	Nome próprio
VERB	VB/VBD/VBG	correr, treinou, processando	Verbo principal
AUX	MD/VBZ(aux)	ser, estar, ter, haver	Verbo auxiliar
ADJ	JJ/JJR/JJS	rápido, melhor, neural	Adjetivo
ADV	RB/RBR	muito, não, rapidamente	Advérbio
ADP	IN	de, em, para, com	Preposição (adposição)
DET	DT	o, a, um, uma, este	Determinante / artigo
PRON	PRP/PRP\$	eu, ele, meu, que	Pronome
CCONJ	CC	e, ou, mas, porém	Conjunção coordenativa
SCONJ	<u>IN</u> (que/se)	que, se, porque, embora	Conjunção subordinativa
NUM	CD	um, dois, 42, 3,14	Numeral
INTJ	UH	ah, uau, ei, opa	Interjeição
PUNCT	./,/!/?	. , ! ? :	Pontuação
SYM	SYM	R\$, %, @, →	Símbolo
X	FW/XX	input (em texto PT)	Estrangeiro / desconhecido
PART	RP/TO	não (partícula)	Partícula

O projeto Universal Dependencies, iniciado em 2014, propôs 17 tags universais (UPOS) que funcionam para qualquer idioma humano. **O spaCy usa UD como padrão para `token.pos_`.**

A grande vantagem é a comparabilidade cross-linguística: a mesma lógica funciona em português, inglês, espanhol ou mandarim.

1.5. Tags morfológicas detalhadas — `token.tag_` e `token.morph`

Um tagset (conjunto de etiquetas) é o inventário de rótulos usados por um sistema de **POS tagging** para categorizar tokens. Vamos estudar os dois mais importantes: o **Penn Treebank (PTB)**, padrão histórico do inglês usado pelo **NLTK**, e o **Universal Dependencies (UD)**, padrão moderno cross-linguístico usado pelo **spaCy**.

Token Bruto

classificou

token.pos_

[VERB]

token.tag_ e token.morph

Mood=Ind | Number=Sing | Person=3 | Tense=Past

A morfologia profunda extrai tempo, gênero e número. Um verbo não é apenas uma ação; é um vetor de estado no tempo.


1.5. Tags morfológicas detalhadas — token.tag_ e token.morph

Token	token.pos_	token.tag_	Informação morfológica
modelo (suj.)	NOUN	NOUN__Gender=Masc Number=Sing	Masculino singular
redes (pl.)	NOUN	NOUN__Gender=Fem Number=Plur	Feminino plural
classificou	VERB	VERB__Mood=Ind Number=Sing Person=3 Tense=Past	Indicativo passado 3ª sing.
processando	VERB	VERB__VerbForm=Ger	Gerúndio
precisos	ADJ	ADJ__Gender=Masc Number=Plur	Adjetivo masc. plural
melhores	ADJ	ADJ__Number=Plur	Superlativo → lema: 'bom'

1.6. Funcionamento do POS Tagger

Existem três grandes gerações de abordagens, cada uma superando as limitações da anterior:

- Geração 1 — Taggers baseados em regras (1960–1990).
- Geração 2 — Taggers estatísticos (1990–2012).
- Geração 3 — Taggers neurais (2012–presente)



1.6. Funcionamento do POS Tagger – Geração 1 — Taggers baseados em regras (1960–1990).


Geração 1 - REGRAS: Os primeiros taggers usavam listas de regras escritas manualmente por linguistas. O TAGGIT (1971) usava 71 tags e ~3.300 regras para inglês. Cada regra especificava: 'se a palavra termina em **-ção** e está precedida de artigo, é **NOUN**'.

Geração 2 – ESTATÍSTICA: Com o Penn Treebank (1992) — **corpus de 1 milhão de palavras anotadas** manualmente — surgiu a possibilidade de treinar modelos estatísticos.

Geração 3 — TAGGERS NEURAIIS: Com o deep learning, os **taggers neurais aprenderam representações hierárquicas** da linguagem sem que os engenheiros precisassem definir cada nível manualmente

1.7. Por que POS Tagging ainda é relevante na era dos LLMs?

1. **Interpretabilidade:** saber que 'banco' foi taggeado como NOUN ajuda a debugar erros.
2. **Eficiência:** um tagger leve é muito mais rápido que um LLM para tarefas simples.
3. **Feature engineering:** POS tags continuam sendo features úteis em modelos híbridos.
4. **Análise linguística:** pesquisadores precisam de anotações morfosintáticas explícitas.
5. **Sistemas com restrições:** ambientes sem GPU dependem de taggers leves.
6. **Pipeline:** POS é a base para parsing sintático, NER e extração de relações.



1.8. Aplicações do POS Tagging em PLN

Aplicação 1 — Lematização mais precisa: a lematização usa a classe gramatical para decidir o lema correto. Sem POS tag, 'melhor' poderia ter lema 'melhor' (advérbio) ou 'bom' (adjetivo superlativo). Com POS tag, o spaCy sempre faz a escolha certa.

Aplicação 2 — Análise de Sentimento por Aspecto (ABSA): o objetivo é identificar não apenas se um texto é positivo ou negativo, mas sobre qual aspecto do produto. O POS tagging é fundamental: Substantivos identificam os aspectos: 'bateria', 'câmera', 'tela' em uma review de celular, Adjetivos identificam o sentimento: 'excelente', 'fraca', 'nítida' e Dependências sintáticas ligam adjetivo ao substantivo que modifica.


1.8. Aplicações do POS Tagging em PLN

Aplicação 3 — Extração de termos e palavras-chave: Uma das formas mais eficazes de extrair palavras-chave é manter apenas as classes que carregam conteúdo semântico: NOUN, PROPN, VERB e ADJ. Essa técnica reduz o vocabulário mantendo os termos mais informativos e é usada em sistemas de indexação e resumo automático.

Aplicação 4 — Reconhecimento de Entidades Nomeadas (NER): O NER (Aula 08) identifica pessoas, organizações, locais e datas. O POS tagging é a base — PROPN é um forte indício de entidade nomeada, e padrões como [DET][ADJ]*[PROPN]+ frequentemente identificam nomes de organizações.

1.8. Aplicações do POS Tagging em PLN

Aplicação 5 — Chunking e parsing sintático: O chunking identifica sintagmas nominais (NP), verbais (VP) e preposicionais (PP). O sintagma nominal tipicamente segue o padrão: [DET?][ADJ*][NOUN][ADJ*]. Sem POS tags, é impossível aplicar essas regras. O parsing de dependências (Aula 09) também usa POS tags como features.



Referências

CASELI, H. M.; NUNES, M. G. V. (org.). Processamento de linguagem natural: conceitos, técnicas e aplicações em português. São Carlos: BPLN, 2023. Cap. 4, pp. 85–120, Cap. 5, pp. 121 - 148.

MARTINS, J. S. et al. Processamento de Linguagem Natural. Porto Alegre: Grupo A, 2024. Cap. 3, pp. 49–72.



IBMEC.BR

 /IBMEC

 IBMEC

 @IBMEC_OFICIAL

 @IBMEC

 **ibmec**