

Aula 04

Representações de Texto

Bag of Words e TF-IDF

PROCESSAMENTO DE LINGUAGEM NATURAL - IBM3130

Prof. Anderson Vanin

Quando se trata de PLN...

Primeira unidade básica

DOCUMENTO

Primeira unidade básica



Texto

Primeira unidade básica

DOCUMENTO

Texto

Uau! Este produto é incrível!

- Um Tweet
- Um Paragrafo de um livro
- Pode ser um livro inteiro!

**BASICAMENTE UMA UNIDADE
QUE CONTÉM TEXTO**

Primeira unidade básica

Uau! Este produto é incrível!

Achei o atendimento ruim

Bateria excelente!

Filme muito bom.

E QUANDO TEMOS VÁRIOS DOCUMENTOS JUNTOS

Primeira unidade básica

Uau! Este produto é incrível!

Achei o atendimento ruim

Bateria excelente!

Filme muito bom.

ESSA COLEÇÃO DE DOCUMENTOS SE CHAMA CORPUS

1. Introdução

Modelos de Processamento de Linguagem Natural (PLN) e Machine Learning não entendem strings de texto diretamente. Eles exigem dados numéricos estruturados. O processo de conversão de texto em vetores numéricos é chamado de extração de características (*Feature Extraction*) ou vetorização.

2. Bag of Words (BoW)

O modelo Bag of Words (Bolsa de Palavras) representa o texto ignorando completamente a ordem das palavras, a gramática e a sintaxe. Ele foca exclusivamente na presença e na frequência das palavras.

O texto é representado pela quantidade de vezes que cada palavra aparece. A ordem das palavras não é considerada!

2.1 Passo a Passo

1. **Tokenização:** Dividir as frases em unidades individuais (palavras).
2. **Construção do Vocabulário:** Reunir todas as palavras únicas de todo o conjunto de textos (corpus).
3. **Vetorização:** Contar quantas vezes cada palavra do vocabulário aparece em cada documento.

2.2 Exemplo

Considere o seguinte corpus com 3 documentos (frases):

D1: "O gato caça o rato. "

D2: "O cachorro caça o gato. "

D3: "O rato corre."

Após aplicar a tokenização e remover a pontuação, o nosso **Vocabulário Único** (ordenado) será:

`['cachorro', 'caça', 'corre', 'gato', 'o', 'rato']`

2.2 Exemplo

A representação em matriz de contagem (**Bag of Words**) final será:

Documento	cachorro	caça	corre	gato	o	rato
D1	0	1	0	1	2	1
D2	1	1	0	1	2	0
D3	0	0	1	0	1	1

2.3 Limitações do BoW

- **Esparsidade:** Matrizes gigantes cheias de zeros caso o vocabulário seja grande.
- **Semântica:** Perda total do contexto (as frases "não é bom, é ruim" e "não é ruim, é bom" geram o mesmo vetor).
- **Viés de frequência:** Palavras muito comuns (como "o", "a", "de") dominam os pesos, mesmo sem trazer significado real.

3 TF-IDF (Term Frequency - Inverse Document Frequency)

O TF-IDF soluciona o problema das palavras comuns do **BoW**. Ele calcula um peso que penaliza palavras frequentes em todo o corpus e valoriza termos exclusivos de um documento específico.

A ideia é descobrir: *Quais palavras são importantes para um determinado documento?*

3 TF-IDF (Term Frequency - Inverse Document Frequency)

Uma palavra que aparece muitas vezes em um documento pode ser importante.

Mas existe uma segunda questão:

Essa palavra também aparece em muitos outros documentos?

Se aparece em todos os documentos, talvez não seja tão útil para diferenciá-los.

3 TF-IDF (Term Frequency - Inverse Document Frequency)

O cálculo do **TF-IDF** é a multiplicação de duas métricas:

$$TF - IDF(t, d, D) = TF(t, d) \times IDF(t, D)$$

1. **TF** (*Term Frequency*) Mede a frequência local de um termo t dentro de um documento específico d .

$$TF(t, d) = \frac{\text{Contagem de } t \text{ em } d}{\text{Total de termos em } d}$$

2. **IDF** (*Inverse Document Frequency*) Mede a importância global do termo em todo o conjunto de documentos D . Se uma palavra aparece em todos os documentos, o seu IDF se aproxima de zero.

$$IDF(t, D) = \log \left(\frac{\text{Total de documentos } |D|}{\text{Documentos que contêm } t} \right)$$

(Nota: Bibliotecas como o Scikit-learn adicionam constantes como +1 na fórmula para evitar divisões por zero e garantir pesos positivos).

4 Exemplo prático de BoW e TF-IDF

O cálculo do **TF-IDF** é a multiplicação de duas métricas:

$$TF - IDF(t, d, D) = TF(t, d) \times IDF(t, D)$$

1. **TF** (*Term Frequency*) Mede a frequência local de um termo t dentro de um documento específico d .

$$TF(t, d) = \frac{\text{Contagem de } t \text{ em } d}{\text{Total de termos em } d}$$

2. **IDF** (*Inverse Document Frequency*) Mede a importância global do termo em todo o conjunto de documentos D . Se uma palavra aparece em todos os documentos, o seu IDF se aproxima de zero.

$$IDF(t, D) = \log \left(\frac{\text{Total de documentos } |D|}{\text{Documentos que contêm } t} \right)$$

Referências

CASELI, H. M.; NUNES, M. G. V. (org.). Processamento de linguagem natural: conceitos, técnicas e aplicações em português. São Carlos: BPLN, 2023. Cap. 6, pp. 149–180.

FACELI, K. et al. Inteligência Artificial: uma abordagem de aprendizado de máquina. Rio de Janeiro: LTC, 2025. Cap. 5, pp. 91–118 e Cap. 8, pp. 155–176.

SICSÚ, A. L.; SAMARTINI, A.; BARTH, N. L. Técnicas de Machine Learning. São Paulo: Editora Blucher, 2023. Cap. 7, pp. 67-88.



IBMEC.BR

 /IBMEC

 IBMEC

 @IBMEC_OFICIAL

 @IBMEC

 **ibmec**